



西安交通大学
XI'AN JIAOTONG UNIVERSITY

计算方法

令 丹

数学与统计学院

邮箱: danling@xjtu.edu.cn



第二章

解线性方程组的直接法

2. 矩阵的三角分解

矩阵的三角分解

对于系数矩阵相同，右端项不同的多个线性方程组

$$Ax = b^{(i)}, i = 1, 2, \dots, m$$

若采用高斯消去法逐个求解，计算量大

$$N = m \left(\frac{1}{3}n^3 + n^2 - \frac{1}{3}n \right) \implies N \sim O(mn^3)$$

如何有效求解？

矩阵的三角分解

高斯消去法的消元过程

对 $k = 1, \dots, n-1$, 依次计算

$$\begin{cases} l_{i,k} = a_{i,k}^{(k-1)} / a_{k,k}^{(k-1)}, & i = k+1, \dots, n, \\ a_{ij}^{(k)} = a_{ij}^{(k-1)} - l_{ik} a_{kj}^{(k-1)}, & i, j = k+1, \dots, n, \\ b_i^{(k)} = b_i^{(k-1)} - l_{ik} b_k^{(k-1)}, & i = k+1, \dots, n. \end{cases}$$

目标：将增广矩阵 $(A^{(0)}, b^{(0)})$ 通过初等行变换 (**左乘矩阵**) 最终变为上梯形矩阵 $(A^{(n-1)}, b^{(n-1)})$, 其中 $A^{(n-1)}$ 为上三角矩阵.

高斯消去法的消元过程

若设 $A^{(k)} = LA^{(k-1)}$, 根据矩阵乘法有

$$\begin{cases} a_{ij}^{(k-1)} = \sum_{m=1}^n L_{im} a_{mj}^{(k-1)} = a_{ij}^{(k-1)}, & i = 1, \dots, k; \quad j = 1, \dots, n; \\ a_{ij}^{(k)} = \sum_{m=1}^n L_{im} a_{mj}^{(k-1)} = a_{ij}^{(k-1)} - l_{ik} a_{kj}^{(k-1)}, & i, j = k+1, \dots, n, \end{cases}$$

于是得到

$$\begin{cases} L_{ii} = 1, & i = 1, \dots, n, \\ L_{jk} = -l_{jk}, & j = k+1, \dots, n. \end{cases}$$

高斯消去法的矩阵形式

记

$$A^{(0)} \triangleq A$$

$$A^{(1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1n}^{(0)} \\ 0 & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} \\ \vdots & \vdots & & \vdots \\ 0 & a_{n2}^{(1)} & \cdots & a_{nn}^{(1)} \end{pmatrix}, \quad L_1 \triangleq \begin{pmatrix} 1 & & & & \\ -l_{21} & 1 & & & \\ -l_{31} & & 1 & & \\ \vdots & & & \ddots & \\ -l_{n1} & & & & 1 \end{pmatrix}$$

则有 $A^{(1)} = L_1 A^{(0)}$.

高斯消去法的矩阵形式

$$A^{(2)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & a_{13}^{(0)} & \cdots & a_{1n}^{(0)} \\ 0 & a_{22}^{(1)} & a_{23}^{(1)} & \cdots & a_{2n}^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \cdots & a_{3n}^{(2)} \\ \vdots & \vdots & \vdots & & \vdots \\ 0 & 0 & a_{n3}^{(2)} & \cdots & a_{nn}^{(2)} \end{pmatrix},$$
$$L_2 \triangleq \begin{pmatrix} 1 & & & & \\ & 1 & & & \\ & -l_{32} & 1 & & \\ & \vdots & & \ddots & \\ & -l_{n2} & & & 1 \end{pmatrix}$$

则 $A^{(2)} = L_2 A^{(1)} = L_2 L_1 A^{(0)}.$

高斯消去法的矩阵形式

一般地,

$$A^{(k-1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & \cdots & a_{2n}^{(1)} \\ & & \ddots & & \vdots \\ & & & a_{kk}^{(k-1)} & \cdots & a_{kn}^{(k-1)} \\ & & & \vdots & & \vdots \\ & & & a_{nk}^{(k-1)} & \cdots & a_{nn}^{(k-1)} \end{pmatrix}$$
$$L_k \triangleq \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & -l_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & -l_{nk} & & & 1 \end{pmatrix}$$

高斯消去法的矩阵形式

$$A^{(k)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1,k+1}^{(0)} & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & a_{2,k+1}^{(1)} & \cdots & a_{2n}^{(1)} \\ & & \ddots & \vdots & & \vdots \\ & & & a_{kk}^{(k-1)} & \cdots & a_{kn}^{(k-1)} \\ & & & a_{k+1,k+1}^{(k)} & \cdots & a_{k+1,n}^{(k)} \\ & & & \vdots & & \vdots \\ & & & a_{n,k+1}^{(k)} & \cdots & a_{nn}^{(k)} \end{pmatrix}$$

则 $A^{(k)} = L_k A^{(k-1)} = \cdots = L_k L_{k-1} \cdots L_2 L_1 A^{(0)}$.

高斯消去法的矩阵形式

由于消元过程进行了 $n - 1$ 步，于是有

$$A^{(n-1)} = L_{n-1}A^{(n-2)} = \cdots = L_{n-1}L_{n-2}\cdots L_2L_1A^{(0)},$$

其中

$$A^{(n-1)} \triangleq \begin{pmatrix} a_{11}^{(0)} & a_{12}^{(0)} & \cdots & a_{1n}^{(0)} \\ & a_{22}^{(1)} & \cdots & a_{2n}^{(1)} \\ & & \ddots & \vdots \\ & & & a_{nn}^{(n-1)} \end{pmatrix}.$$

同理，对于右端项有

$$b^{(n-1)} = L_{n-1}L_{n-2}\cdots L_2L_1b^{(0)}.$$

高斯消去法的矩阵形式

注意到

$$L_k^{-1} = \begin{pmatrix} 1 & & & & \\ & \ddots & & & \\ & & 1 & & \\ & & l_{k+1,k} & 1 & \\ & & \vdots & & \ddots \\ & & l_{nk} & & & 1 \end{pmatrix}$$

则有

$$A = A^{(0)} = L_1^{-1} L_2^{-1} \cdots L_{n-1}^{-1} A^{(n-1)} = LU, \quad b = b^{(0)} = Lb^{(n-1)},$$

高斯消去法的矩阵形式

其中

$$L \triangleq L_1^{-1} L_2^{-1} \cdots L_{n-1}^{-1} = \begin{pmatrix} 1 & & & & \\ l_{21} & 1 & & & \\ l_{31} & l_{32} & 1 & & \\ \vdots & \vdots & & \ddots & \\ l_{n1} & l_{n2} & \cdots & l_{n,n-1} & 1 \end{pmatrix},$$
$$U \triangleq A^{(n-1)} = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ & u_{22} & \cdots & u_{2n} \\ & & \ddots & \vdots \\ & & & u_{nn} \end{pmatrix}.$$

$A = LU$, 其中 L 是单位下三角矩阵, U 是上三角矩阵.

矩阵的三角分解

定理

设 A 为 n 阶矩阵, 如果 A 的顺序主子式 $D_k \neq 0$ ($k = 1, \dots, n$), 则 A 可以唯一地分解为一个单位下三角矩阵 L 与一个上三角矩阵 U 的乘积, 即 $A = LU$.

证明 存在性: 由高斯消去法的矩阵形式可得.

唯一性: (反证法) 设 A 有两种 LU 分解

$$A = L_1 U_1 = L_2 U_2,$$

其中 L_1, L_2 为单位下三角矩阵, U_1, U_2 为上三角矩阵. 由于 A 非奇异, 即 A 可逆. 于是有

$$A^{-1} = U_1^{-1} L_1^{-1} = U_2^{-1} L_2^{-1} \implies U_2 U_1^{-1} = L_2^{-1} L_1.$$

上式中左端为上三角矩阵, 右端为单位下三角矩阵, 因此

$$U_2 U_1^{-1} = L_2^{-1} L_1 = I \implies U_1 = U_2, L_1 = L_2.$$

矩阵的 LU 分解

- 矩阵的 LU 分解

$A = LU$, 其中 L 是下三角矩阵, U 是上三角矩阵.

- 两种常见的 LU 分解

Doolittle 分解 L 为单位下三角矩阵, U 为上三角矩阵

Crout 分解 L 为下三角矩阵, U 为单位上三角矩阵

矩阵的 LU 分解 (Doolittle 分解)

对于给定的非奇异矩阵 A , 如何计算 L 和 U ?

设

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix}, \quad L = \begin{pmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ l_{n1} & l_{n2} & \cdots & l_{n,n-1} & 1 \end{pmatrix},$$

$$U = \begin{pmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ & u_{22} & \cdots & u_{2n} \\ & & \ddots & \vdots \\ & & & u_{nn} \end{pmatrix}.$$

$$\begin{cases} l_{ii} = 1, \quad l_{ik} = 0, \quad i < k \\ u_{kj} = 0, \quad j < k \end{cases} \implies \text{如何确定 } l_{ik} (k \leq i) \text{ 以及 } u_{kj} (k \leq j)?$$

矩阵的 LU 分解 (Doolittle 分解)

由 $A = LU$ 可知,

$$a_{ij} = \sum_{k=1}^n l_{ik} u_{kj} = \sum_{k=1}^{\min\{i,j\}} l_{ik} u_{kj}, \quad i, j = 1, 2, \dots, n.$$

矩阵的 LU 分解 (Doolittle 分解)

由 $A = LU$ 可知,

$$a_{ij} = \sum_{k=1}^n l_{ik} u_{kj} = \sum_{k=1}^{\min\{i,j\}} l_{ik} u_{kj}, \quad i, j = 1, 2, \dots, n.$$

若 $i \leq j$, 则有 $a_{ij} = \sum_{k=1}^i l_{ik} u_{kj}$, 于是

$$\Rightarrow \begin{cases} a_{1j} = l_{11} u_{1j}, & j = 1, 2, \dots, n \\ a_{ij} = \sum_{k=1}^{i-1} l_{ik} u_{kj} + u_{ij}, & i = 2, 3, \dots, n; j = i, i+1, \dots, n \\ u_{1j} = a_{1j}, & j = 1, 2, \dots, n \\ u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}, & i = 2, 3, \dots, n; j = i, i+1, \dots, n \end{cases}$$

矩阵的 LU 分解 (Doolittle 分解)

若 $i > j$, 则有 $a_{ij} = \sum_{k=1}^j l_{ik}u_{kj}$, 于是

$$\Rightarrow \begin{cases} a_{i1} = l_{i1}u_{11}, & i = 2, 3, \dots, n \\ a_{ij} = \sum_{k=1}^{j-1} l_{ik}u_{kj} + l_{ij}u_{jj}, & j = 2, 3, \dots, n-1; i = j+1, \dots, n \\ l_{i1} = \frac{a_{i1}}{u_{11}}, & i = 2, 3, \dots, n \\ l_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} l_{ik}u_{kj}}{u_{jj}}, & j = 2, 3, \dots, n-1; i = j+1, \dots, n \end{cases}$$

矩阵的 LU 分解

$A = LU$ 分解计算公式:

$$\begin{cases} u_{1j} = a_{1j}, & j = 1, 2, \dots, n \\ l_{i1} = \frac{a_{i1}}{u_{11}}, & i = 2, 3, \dots, n \\ u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}, & i = 2, 3, \dots, n; j = i, i+1, \dots, n \\ l_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} l_{ik} u_{kj}}{u_{jj}}, & j = 2, 3, \dots, n-1; i = j+1, \dots, n \end{cases}$$

先计算矩阵 U 的第 i 行, 再计算矩阵 L 的第 i 列.

矩阵 LU 分解的计算量

乘法:

$$\begin{aligned} N_1 &= \sum_{i=2}^n (i-1)(n-i+1) + \sum_{j=2}^{n-1} (j-1)(n-j) \\ &= (n-1) \left(\frac{1}{3}n^2 - \frac{1}{6}n \right) \end{aligned}$$

除法:

$$N_2 = n-1 + \sum_{j=2}^{n-1} (n-j) = \frac{1}{2}n(n-1)$$

矩阵 LU 分解的计算量

乘法:

$$\begin{aligned} N_1 &= \sum_{i=2}^n (i-1)(n-i+1) + \sum_{j=2}^{n-1} (j-1)(n-j) \\ &= (n-1) \left(\frac{1}{3}n^2 - \frac{1}{6}n \right) \end{aligned}$$

除法:

$$N_2 = n-1 + \sum_{j=2}^{n-1} (n-j) = \frac{1}{2}n(n-1)$$

$$\Rightarrow N = N_1 + N_2 = \frac{1}{3}n^3 - \frac{1}{3}n$$

矩阵的 LU 分解

例 1: 求下列矩阵的 Doolittle 分解.

$$A = \begin{pmatrix} 4 & -2 & 0 & 4 \\ -2 & 2 & -3 & 1 \\ 0 & 3 & -13 & 7 \\ 4 & 1 & -1 & 23 \end{pmatrix}.$$

矩阵的 LU 分解

例 1: 求下列矩阵的 Doolittle 分解.

$$A = \begin{pmatrix} 4 & -2 & 0 & 4 \\ -2 & 2 & -3 & 1 \\ 0 & 3 & -13 & 7 \\ 4 & 1 & -1 & 23 \end{pmatrix}.$$

解: 由计算公式, 我们可依次求得

$$\begin{aligned} u_{11} &= 4, & u_{12} &= -2, & u_{13} &= 0, & u_{14} &= 4, \\ l_{21} &= -\frac{1}{2}, & u_{22} &= 1, & u_{23} &= -3, & u_{24} &= 3, \\ l_{31} &= 0, & l_{32} &= 3, & u_{33} &= -4, & u_{34} &= -2, \\ l_{41} &= 1, & l_{42} &= 3, & l_{43} &= -2, & u_{44} &= 6. \end{aligned}$$

矩阵的 LU 分解

例 1: 求下列矩阵的 Doolittle 分解.

$$A = \begin{pmatrix} 4 & -2 & 0 & 4 \\ -2 & 2 & -3 & 1 \\ 0 & 3 & -13 & 7 \\ 4 & 1 & -1 & 23 \end{pmatrix}.$$

$$\Rightarrow L = \begin{pmatrix} 1 & & & \\ -\frac{1}{2} & 1 & & \\ 0 & 3 & 1 & \\ 1 & 3 & -2 & 1 \end{pmatrix}, U = \begin{pmatrix} 4 & -2 & 0 & 4 \\ & 1 & -3 & 3 \\ & & -4 & -2 \\ & & & 6 \end{pmatrix}.$$

LU 分解法求线性方程组 $Ax = b$

基本思路:

$$Ax = LUx = b \implies \begin{cases} Ly = b \\ Ux = y \end{cases}$$

主要步骤:

① 解方程组 $Ly = b$, 即有 $\sum_{j=1}^i l_{ij}y_j = b_i$, $i = 1, 2, \dots, n$, 于是

$$\begin{cases} y_1 = b_1, \\ y_i = b_i - \sum_{j=1}^{i-1} l_{ij}y_j, \quad i = 2, 3, \dots, n \end{cases}$$

从 y 的计算公式可以看出, y 的计算可与 $A = LU$ 同时进行:
对 A 的增广矩阵 $\tilde{A} = (A, b)$ 进行分解 $\tilde{A} = L\tilde{U} = L(U, y)$.

LU 分解法求线性方程组 $Ax = b$

主要步骤:

② 解方程组 $Ux = y$ (高斯消去法的回代过程), 即

$$\sum_{j=i}^n u_{ij}x_j = y_i, \quad i = 1, 2, \dots, n,$$

因此得到

$$\begin{cases} x_n = \frac{y_n}{u_{nn}}, \\ x_i = \frac{y_i - \sum_{j=i+1}^n u_{ij}x_j}{u_{ii}}, \quad i = n-1, \dots, 1 \end{cases}$$

LU 分解法求线性方程组的运算量

$$(1) A = LU : N_1 = \frac{1}{3}n^3 - \frac{1}{3}n$$

$$(2) Ly = b : N_2 = \sum_{i=2}^n (i-1) = \frac{1}{2}n(n-1)$$

$$(3) Ux = y : N_3 = n + \sum_{i=1}^{n-1} (n-i) = \frac{1}{2}n(n+1)$$

因此应用 LU 分解求方程组 $Ax = b$ 的乘除法运算次数为

$$N = N_1 + N_2 + N_3 = \frac{1}{3}n^3 + n^2 - \frac{1}{3}n,$$

与高斯消去法的乘除法运算量相同.

矩阵三角分解的应用

求解具有相同系数矩阵 A 和不同右端项的多个线性方程组

$$Ax = b^{(i)}, \quad i = 1, 2, \dots, m$$

先求 $A = LU$, 再求解 $2m$ 个线性方程组

$$Ly^{(i)} = b^{(i)}, \quad Ux^{(i)} = y^{(i)}, \quad i = 1, 2, \dots, m$$

乘除法运算量:

$$N = \frac{1}{3}n^3 - \frac{1}{3}n + mn^2.$$

当 $m \sim O(n)$ 时, $N \sim O(n^3)$. 对比高斯消去法

$$N = m \left(\frac{1}{3}n^3 + n^2 - \frac{1}{3}n \right) \sim O(n^4)$$

矩阵的 LU 分解

例 2: 用 $A = LU$ 求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 1 & 2 & 1 & -3 \\ 2 & 5 & 0 & -5 \\ 1 & 0 & 14 & 1 \\ -3 & -5 & 1 & 15 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

解: 先求增广矩阵 $\tilde{A} = (A, b)$ 的 $\tilde{A} = L\tilde{U} = L(U, y)$ 分解.

① 由 $\tilde{u}_{1j} = \tilde{a}_{1j}$ ($j = 1, 2, 3, 4, 5$) 得

$$\tilde{u}_{11} = 1, \quad \tilde{u}_{12} = 2, \quad \tilde{u}_{13} = 1, \quad \tilde{u}_{14} = -3, \quad \tilde{u}_{15} = 1$$

矩阵的 LU 分解

例 2: 用 $A = LU$ 求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 1 & 2 & 1 & -3 \\ 2 & 5 & 0 & -5 \\ 1 & 0 & 14 & 1 \\ -3 & -5 & 1 & 15 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

解: 先求增广矩阵 $\tilde{A} = (A, b)$ 的 $\tilde{A} = L\tilde{U} = L(U, y)$ 分解.

① 由 $\tilde{u}_{1j} = \tilde{a}_{1j}$ ($j = 1, 2, 3, 4, 5$) 得

$$\tilde{u}_{11} = 1, \quad \tilde{u}_{12} = 2, \quad \tilde{u}_{13} = 1, \quad \tilde{u}_{14} = -3, \quad \tilde{u}_{15} = 1$$

② 由 $l_{i1} = \tilde{a}_{i1}/\tilde{u}_{11}$ ($i = 2, 3, 4$) 得

$$l_{21} = 2, \quad l_{31} = 1, \quad l_{41} = -3$$

矩阵的 LU 分解

③ 由 $\tilde{u}_{2j} = \tilde{a}_{2j} - l_{21}\tilde{u}_{1j}$ ($j = 2, 3, 4, 5$) 得

$$\tilde{u}_{22} = 1, \quad \tilde{u}_{23} = -2, \quad \tilde{u}_{24} = 1, \quad \tilde{u}_{25} = 0$$

④ 由 $l_{i2} = (\tilde{a}_{i2} - l_{i1}\tilde{u}_{12})/\tilde{u}_{22}$ ($i = 3, 4$) 得

$$l_{32} = -2, \quad l_{42} = 1$$

⑤ 由 $\tilde{u}_{3j} = \tilde{a}_{3j} - l_{31}\tilde{u}_{1j} - l_{32}\tilde{u}_{2j}$ ($j = 3, 4, 5$) 得

$$\tilde{u}_{33} = 9, \quad \tilde{u}_{34} = 6, \quad \tilde{u}_{35} = 15$$

⑥ $l_{43} = (\tilde{a}_{43} - l_{41}\tilde{u}_{13} - l_{42}\tilde{u}_{23})/\tilde{u}_{33} = \frac{2}{3}$

矩阵的 LU 分解

③ 由 $\tilde{u}_{2j} = \tilde{a}_{2j} - l_{21}\tilde{u}_{1j}$ ($j = 2, 3, 4, 5$) 得

$$\tilde{u}_{22} = 1, \quad \tilde{u}_{23} = -2, \quad \tilde{u}_{24} = 1, \quad \tilde{u}_{25} = 0$$

④ 由 $l_{i2} = (\tilde{a}_{i2} - l_{i1}\tilde{u}_{12})/\tilde{u}_{22}$ ($i = 3, 4$) 得

$$l_{32} = -2, \quad l_{42} = 1$$

⑤ 由 $\tilde{u}_{3j} = \tilde{a}_{3j} - l_{31}\tilde{u}_{1j} - l_{32}\tilde{u}_{2j}$ ($j = 3, 4, 5$) 得

$$\tilde{u}_{33} = 9, \quad \tilde{u}_{34} = 6, \quad \tilde{u}_{35} = 15$$

⑥ $l_{43} = (\tilde{a}_{43} - l_{41}\tilde{u}_{13} - l_{42}\tilde{u}_{23})/\tilde{u}_{33} = \frac{2}{3}$

⑦ 由 $\tilde{u}_{4j} = \tilde{a}_{4j} - l_{41}\tilde{u}_{1j} - l_{42}\tilde{u}_{2j} - l_{43}\tilde{u}_{3j}$ ($j = 4, 5$) 得

$$\tilde{u}_{44} = 1, \quad \tilde{u}_{45} = 1$$

矩阵的 LU 分解

于是有

$$L = \begin{pmatrix} 1 & & & \\ 2 & 1 & & \\ 1 & -2 & 1 & \\ -3 & 1 & \frac{2}{3} & 1 \end{pmatrix}, U = \begin{pmatrix} 1 & -2 & 1 & 3 \\ & 1 & -2 & 1 \\ & & 9 & 6 \\ & & & 1 \end{pmatrix}, y = \begin{pmatrix} 1 \\ 0 \\ 15 \\ 1 \end{pmatrix}$$

再由 $Ux = y$ 解得

$$x = (1, 1, 1, 1)^T.$$

$$LUx = b,$$

$$Ux = L^{-1}b = y$$

特殊矩阵的三角分解

若 A 对称, $A = LU$?

若 A 对称正定, $A = LU$?

特殊矩阵的三角分解

若 A 对称, $A = LU$?

若 A 对称正定, $A = LU$?

定理

设 A 为 n 阶对称矩阵, 若 A 的各阶顺序主子式不为零, 则 A 可以唯一分解为

$$A = LDL^T,$$

其中 L 为单位下三角矩阵, D 是对角矩阵.

对称矩阵的三角分解

证明 根据定理条件可知 $A = LU$, 其中 L 为单位下三角矩阵, U 为上三角矩阵. 设

$$D = \text{diag}(d_1, d_2, \dots, d_n) = \text{diag}(u_{11}, u_{22}, \dots, u_{nn}),$$

则 D 可逆. 于是有 $A = LU = LDD^{-1}U = LDM^T$, 其中 $M^T = D^{-1}U$, M 为单位下三角矩阵. 另一方面, 由 A 对称得

$$LU = A = A^T = (LU)^T = (LDM^T)^T = M(LD)^T,$$

注意到 $(LD)^T$ 是上三角矩阵. 注意到等式两端都是矩阵 A 的 Doolittle 分解. 根据分解的唯一性有

$$L = M \implies A = LDM^T = LDL^T.$$

$A = LDL^T$ 分解

由于 A 对称且 L 是单位下三角矩阵, 因此我们仅考虑 A 的下半部分元素, 即 $i \geq j$ 的情形. 根据 $A = LDL^T$, 由矩阵乘法得

$$a_{ij} = \sum_{k=1}^n l_{ik} d_k l_{jk} = \sum_{k=1}^{\min\{i,j\}} l_{ik} d_k l_{jk} = \sum_{k=1}^j l_{ik} d_k l_{jk}.$$

$A = LDL^T$ 分解

由于 A 对称且 L 是单位下三角矩阵, 因此我们仅考虑 A 的下半部分元素, 即 $i \geq j$ 的情形. 根据 $A = LDL^T$, 由矩阵乘法得

$$a_{ij} = \sum_{k=1}^n l_{ik} d_k l_{jk} = \sum_{k=1}^{\min\{i,j\}} l_{ik} d_k l_{jk} = \sum_{k=1}^j l_{ik} d_k l_{jk}.$$

当 $j = i$ 时,

$$\begin{cases} a_{11} = l_{11}^2 d_1 = d_1, \\ a_{ii} = \sum_{k=1}^i l_{ik}^2 d_k = d_i + \sum_{k=1}^{i-1} l_{ik}^2 d_k, \quad i = 2, \dots, n, \end{cases}$$
$$\Rightarrow \begin{cases} d_1 = a_{11}, \\ d_i = a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 d_k, \quad i = 2, \dots, n. \end{cases}$$

$A = LDL^T$ 分解

当 $j < i$ 时,

$$\begin{cases} a_{i1} = l_{i1}d_1, & i = 2, \dots, n, \\ a_{ij} = l_{ij}d_j + \sum_{k=1}^{j-1} l_{ik}d_kl_{jk}, & j = 2, \dots, n-1; i = j+1, \dots, n, \end{cases}$$
$$\Rightarrow \begin{cases} l_{i1} = \frac{a_{i1}}{d_1}, & i = 2, \dots, n, \\ l_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} l_{ik}d_kl_{jk}}{d_j}, & j = 2, \dots, n-1; i = j+1, \dots, n. \end{cases}$$

$A = LDL^T$ 分解

因此得 $A = LDL^T$ 分解公式如下：

$$\begin{cases} d_1 = a_{11}, \\ l_{i1} = a_{i1}/d_1, \quad i = 2, \dots, n, \\ d_i = a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 d_k, \quad i = 2, \dots, n. \\ l_{ij} = \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} \right) / d_j, \quad j = 2, \dots, n-1; \quad i = j+1, \dots, n. \end{cases}$$

$A = LDL^T$ 分解

因此得 $A = LDL^T$ 分解公式如下:

$$\begin{cases} d_1 = a_{11}, \\ l_{i1} = a_{i1}/d_1, \quad i = 2, \dots, n, \\ d_i = a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 d_k, \quad i = 2, \dots, n. \\ l_{ij} = \left(a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} \right) / d_j, \quad j = 2, \dots, n-1; \quad i = j+1, \dots, n. \end{cases}$$

乘除法运算量:

$$\begin{aligned} N &= n-1 + \sum_{j=2}^{n-1} (n-j) + 2 \left(\sum_{i=2}^n (i-1) + \sum_{j=2}^{n-1} (n-j)(j-1) \right) \\ &= \frac{1}{6}n(n-1)(2n-1) = \frac{1}{3}n^3 - \frac{1}{2}n^2 + \frac{1}{6}n \end{aligned}$$

$A = LDL^T$ 分解

事实上根据 $A = LU = LDL^T$ 和 $L^T = D^{-1}U$ 以及

$$D = \text{diag}(d_1, d_2, \dots, d_n) = \text{diag}(u_{11}, u_{22}, \dots, u_{nn}),$$

我们可得

$$a_{ij} = \sum_{k=1}^n l_{ik} u_{kj} = \sum_{k=1}^{\min\{i,j\}} l_{ik} u_{kj}, \quad i, j = 1, \dots, n,$$
$$l_{ji} = \frac{u_{ij}}{u_{ii}}, \quad i = 1, \dots, n-1; \quad j = i+1, \dots, n.$$

由于 A 对称, 以及 U 是上三角矩阵, 因此我们只考虑 A 的上半部分, 即 $i \leq j$ 的情形. 于是有

$$\begin{cases} a_{1j} = u_{1j}, & j = 1, \dots, n \\ a_{ij} = u_{ij} + \sum_{k=1}^{i-1} l_{ik} u_{kj}, & i = 2, \dots, n; \quad j = i, \dots, n. \end{cases}$$

$A = LDL^T$ 分解

据此得 $A = LDL^T$ 分解公式如下:

$$\begin{cases} u_{1j} = a_{1j}, & j = 1, \dots, n, \\ u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}, & i = 2, \dots, n; \quad j = i, \dots, n, \\ l_{ji} = \frac{u_{ij}}{u_{ii}}, & i = 1, \dots, n-1; \quad j = i+1, \dots, n, \\ d_i = u_{ii}, & i = 1, \dots, n. \end{cases}$$

乘法运算量:

$$N = \sum_{i=1}^{n-1} (n-i) + \sum_{i=2}^n (n+1-i)(i-1) = \frac{1}{6}n^3 + \frac{1}{2}n^2 - \frac{2}{3}n$$

相比前一种分解方式, 运算次数减少了几近一半

对称正定矩阵的 Cholesky 分解

定理

设 A 为 n 阶对称正定矩阵, 则存在一个可逆的下三角矩阵 G 使得

$$A = GG^T,$$

当限定 G 的对角元为正时, 这种分解是唯一的.

证明 由于 A 对称正定则各阶顺序主子式大于零, 由前面的定理可知 $A = LDL^T$, L 为单位下三角矩阵. 由 A 对称正定知

$$\forall x \neq 0, x^T Ax = x^T LDL^T x = (L^T x)^T D L^T x > 0$$

对称正定矩阵的 Cholesky 分解

若令 $y = L^T x$ 则

$$\forall x \neq 0 \text{ 有 } y \neq 0 \text{ 且 } y^T D y > 0.$$

因此 D 对称正定, 即有 $d_i = u_{ii} > 0, i = 1, 2, \dots, n$.

记 $D^{\frac{1}{2}} = \text{diag}(\sqrt{u_{11}}, \sqrt{u_{22}}, \dots, \sqrt{u_{nn}})$, 则

$$A = LDL^T = LD^{\frac{1}{2}} D^{\frac{1}{2}} L^T = (LD^{\frac{1}{2}})(LD^{\frac{1}{2}})^T \triangleq GG^T,$$

其中 $G = LD^{\frac{1}{2}}$ 为下三角矩阵, 且

$$|G| = |LD^{\frac{1}{2}}| = |D^{\frac{1}{2}}| = \sqrt{u_{11}u_{22}\cdots u_{nn}} > 0,$$

即 G 可逆.

对称正定矩阵的 Cholesky 分解

由于 G 是下三角矩阵 ($g_{ij} = 0, i < j$), 我们设

$$G = \begin{pmatrix} g_{11} & & & & \\ g_{21} & g_{22} & & & \\ g_{31} & g_{32} & g_{33} & & \\ \vdots & \vdots & & \ddots & \\ g_{n1} & g_{n2} & \cdots & g_{n,n-1} & g_{nn} \end{pmatrix}.$$

根据 A 的对称性, 我们仅考虑 A 的下半部分元素, 即 $i \geq j$ 的情形. 由 $A = GG^T$ 可知

$$a_{ij} = \sum_{k=1}^n g_{ik}g_{jk} = \sum_{k=1}^{\min\{i,j\}} g_{ik}g_{jk} = \sum_{k=1}^j g_{ik}g_{jk}.$$

对称正定矩阵的 Cholesky 分解

当 $i = j$ 时,

$$\begin{cases} a_{11} = g_{11}^2, \\ a_{jj} = g_{jj}^2 + \sum_{k=1}^{j-1} g_{jk}^2, \quad j = 2, 3, \dots, n \end{cases}$$
$$\Rightarrow \begin{cases} g_{11} = \sqrt{a_{11}}, \\ g_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} g_{jk}^2}, \quad j = 2, 3, \dots, n \end{cases}$$

对称正定矩阵的 Cholesky 分解

当 $i > j$ 时,

$$\begin{cases} a_{i1} = g_{i1}g_{11}, \\ a_{ij} = g_{ij}g_{jj} + \sum_{k=1}^{j-1} g_{ik}g_{jk}, \quad j = 2, 3, \dots, n \end{cases}$$

对称正定矩阵的 Cholesky 分解

当 $i > j$ 时,

$$\begin{cases} a_{i1} = g_{i1}g_{11}, \\ a_{ij} = g_{ij}g_{jj} + \sum_{k=1}^{j-1} g_{ik}g_{jk}, \quad j = 2, 3, \dots, n \end{cases}$$
$$\Rightarrow \begin{cases} g_{i1} = \frac{a_{i1}}{g_{11}}, \quad i = 2, 3, \dots, n \\ g_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} g_{ik}g_{jk}}{g_{jj}}, \quad j = 1, 2, \dots, n-1; \quad i = j+1, \dots, n \end{cases}$$

对称正定矩阵的 Cholesky 分解

Cholesky 分解计算公式:

$$\begin{cases} g_{11} = \sqrt{a_{11}}, \\ g_{i1} = \frac{a_{i1}}{g_{11}}, \quad i = 2, 3, \dots, n \\ g_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} g_{jk}^2}, \quad j = 2, 3, \dots, n \\ g_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} g_{ik}g_{jk}}{g_{jj}}, \quad j = 2, 3, \dots, n-1; \quad i = j+1, \dots, n \end{cases}$$

对称正定矩阵的 Cholesky 分解

由 Cholesky 分解公式可知

$$a_{jj} = \sum_{k=1}^j g_{jk}^2 \implies |g_{jk}| \leq \sqrt{a_{jj}}, \quad j = 1, 2, \dots, n; \quad k = 1, 2, \dots, j.$$

舍入误差可控, Cholesky 分解算法数值稳定.

Cholesky 分解的乘除法运算量:

$$\text{乘法: } N_1 = \sum_{j=2}^n (j-1) + \sum_{j=2}^{n-1} (j-1)(n-j) = \frac{1}{6}(n^3 - n),$$

$$\text{除法: } N_2 = n - 1 + \sum_{j=2}^{n-1} (n-j) = \frac{1}{2}n(n-1),$$

$$\implies N = \frac{1}{6}n^3 + \frac{1}{2}n^2 - \frac{2}{3}n$$

Cholesky 分解求线性方程组——平方根法

假设 A 对称正定

$$Ax = b \implies GG^T x = b \implies \begin{cases} Gy = b \implies \text{解出 } y, \\ G^T x = y \implies \text{解出 } x. \end{cases}$$

由 $Gy = b$ 知

$$\begin{cases} g_{11}y_1 = b_1, \\ \sum_{j=1}^{i-1} g_{ij}y_j + g_{ii}y_i = b_i, \quad i = 2, \dots, n. \end{cases}$$
$$\implies \begin{cases} y_1 = b_1/g_{11}, \\ y_i = \frac{b_i - \sum_{j=1}^{i-1} g_{ij}y_j}{g_{ii}}, \quad i = 2, \dots, n. \end{cases}$$

然后从 $G^T x = y$ 解出 x .

平方根法的乘除法运算量

$$\textcircled{1} \quad A = GG^T : N_1 = \frac{1}{6}n^3 + \frac{1}{2}n^2 - \frac{2}{3}n$$

$$\textcircled{2} \quad Gy = b : N_2 = n + \sum_{i=2}^n (i-1) = \frac{1}{2}n(n+1)$$

$$\textcircled{3} \quad G^T x = y : N_3 = N_2 = \frac{1}{2}n(n+1)$$

$$N = N_1 + N_2 + N_3 = \frac{1}{6}n^3 + \frac{3}{2}n^2 + \frac{1}{3}n$$

对比高斯消去法和 Doolittle 分解法,

$$N = \frac{1}{3}n^3 + n^2 - \frac{1}{3}n$$

运算量几乎减少了一半. 但是平方根法包含 n 次开方运算, 需要消耗较多的时间.

平方根法

例 3: 用平方根法求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 1 & 2 & 1 & -3 \\ 2 & 5 & 0 & -5 \\ 1 & 0 & 14 & 1 \\ -3 & -5 & 1 & 15 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

平方根法

例 3: 用平方根法求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 1 & 2 & 1 & -3 \\ 2 & 5 & 0 & -5 \\ 1 & 0 & 14 & 1 \\ -3 & -5 & 1 & 15 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

解: 先求增广矩阵 $\tilde{A} = (A, b)$ 的 $\tilde{A} = G\tilde{G}^T = G(G^T, y)$ 分解.

平方根法

例 3: 用平方根法求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 1 & 2 & 1 & -3 \\ 2 & 5 & 0 & -5 \\ 1 & 0 & 14 & 1 \\ -3 & -5 & 1 & 15 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

解: 先求增广矩阵 $\tilde{A} = (A, b)$ 的 $\tilde{A} = G\tilde{G}^T = G(G^T, y)$ 分解.

① 由 $g_{11} = \sqrt{a_{11}}$ 得 $g_{11} = 1$

平方根法

例 3: 用平方根法求解线性方程组 $Ax = b$, 其中

$$A = \begin{pmatrix} 1 & 2 & 1 & -3 \\ 2 & 5 & 0 & -5 \\ 1 & 0 & 14 & 1 \\ -3 & -5 & 1 & 15 \end{pmatrix}, \quad b = \begin{pmatrix} 1 \\ 2 \\ 16 \\ 8 \end{pmatrix}.$$

解: 先求增广矩阵 $\tilde{A} = (A, b)$ 的 $\tilde{A} = G\tilde{G}^T = G(G^T, y)$ 分解.

- ① 由 $g_{11} = \sqrt{a_{11}}$ 得 $g_{11} = 1$
- ② 由 $\tilde{g}_{i1} = \tilde{a}_{i1}/g_{11}$ ($i = 2, 3, 4, 5$) 得

$$g_{21} = 2, \quad g_{31} = 1, \quad g_{41} = -3, \quad y_1 = 1$$

平方根法

③ 由 $g_{22} = \sqrt{a_{22} - g_{21}^2}$ 得 $g_{22} = 1$

平方根法

③ 由 $g_{22} = \sqrt{a_{22} - g_{21}^2}$ 得 $g_{22} = 1$

④ 由 $\tilde{g}_{i2} = (\tilde{a}_{i2} - g_{21}\tilde{g}_{i1})/g_{22}$ ($i = 3, 4, 5$) 得

$$g_{32} = -2, \quad g_{42} = 1, \quad y_2 = 0$$

平方根法

③ 由 $g_{22} = \sqrt{a_{22} - g_{21}^2}$ 得 $g_{22} = 1$

④ 由 $\tilde{g}_{i2} = (\tilde{a}_{i2} - g_{21}\tilde{g}_{i1})/g_{22}$ ($i = 3, 4, 5$) 得

$$g_{32} = -2, \quad g_{42} = 1, \quad y_2 = 0$$

⑤ 由 $g_{33} = \sqrt{a_{33} - g_{31}^2 - g_{32}^2}$ 得 $g_{33} = 3$

平方根法

③ 由 $g_{22} = \sqrt{a_{22} - g_{21}^2}$ 得 $g_{22} = 1$

④ 由 $\tilde{g}_{i2} = (\tilde{a}_{i2} - g_{21}\tilde{g}_{i1})/g_{22}$ ($i = 3, 4, 5$) 得

$$g_{32} = -2, \quad g_{42} = 1, \quad y_2 = 0$$

⑤ 由 $g_{33} = \sqrt{a_{33} - g_{31}^2 - g_{32}^2}$ 得 $g_{33} = 3$

⑥ 由 $\tilde{g}_{i3} = (\tilde{a}_{i3} - g_{31}\tilde{g}_{i1} - g_{32}\tilde{g}_{i2})/g_{33}$ ($i = 4, 5$) 得

$$g_{43} = 2, \quad y_3 = 5$$

平方根法

③ 由 $g_{22} = \sqrt{a_{22} - g_{21}^2}$ 得 $g_{22} = 1$

④ 由 $\tilde{g}_{i2} = (\tilde{a}_{i2} - g_{21}\tilde{g}_{i1})/g_{22}$ ($i = 3, 4, 5$) 得

$$g_{32} = -2, \quad g_{42} = 1, \quad y_2 = 0$$

⑤ 由 $g_{33} = \sqrt{a_{33} - g_{31}^2 - g_{32}^2}$ 得 $g_{33} = 3$

⑥ 由 $\tilde{g}_{i3} = (\tilde{a}_{i3} - g_{31}\tilde{g}_{i1} - g_{32}\tilde{g}_{i2})/g_{33}$ ($i = 4, 5$) 得

$$g_{43} = 2, \quad y_3 = 5$$

⑦ 由 $g_{44} = \sqrt{a_{44} - g_{41}^2 - g_{42}^2 - g_{43}^2}$ 得 $g_{44} = 1$

平方根法

③ 由 $g_{22} = \sqrt{a_{22} - g_{21}^2}$ 得 $g_{22} = 1$

④ 由 $\tilde{g}_{i2} = (\tilde{a}_{i2} - g_{21}\tilde{g}_{i1})/g_{22}$ ($i = 3, 4, 5$) 得

$$g_{32} = -2, \quad g_{42} = 1, \quad y_2 = 0$$

⑤ 由 $g_{33} = \sqrt{a_{33} - g_{31}^2 - g_{32}^2}$ 得 $g_{33} = 3$

⑥ 由 $\tilde{g}_{i3} = (\tilde{a}_{i3} - g_{31}\tilde{g}_{i1} - g_{32}\tilde{g}_{i2})/g_{33}$ ($i = 4, 5$) 得

$$g_{43} = 2, \quad y_3 = 5$$

⑦ 由 $g_{44} = \sqrt{a_{44} - g_{41}^2 - g_{42}^2 - g_{43}^2}$ 得 $g_{44} = 1$

⑧ 由 $y_4 = (b_4 - \sum_{k=1}^3 g_{4k}y_k)/g_{44}$ 得 $y_4 = 1$

平方根法

于是有

$$G = \begin{pmatrix} 1 & & & \\ 2 & 1 & & \\ 1 & -2 & 3 & \\ -3 & 1 & 2 & 1 \end{pmatrix}, \quad y = \begin{pmatrix} 1 \\ 0 \\ 5 \\ 1 \end{pmatrix}$$

再由 $G^T x = y$ 解得

$$x = (1, 1, 1, 1)^T.$$

改进平方根法

改进平方根法：用 $A = LDL^T$ 分解方法求解线性方程组 $Ax = b$

$$Ax = b \implies LDL^T x = b \implies \begin{cases} Lz = b \implies \text{解出 } z, \\ Dy = z \implies \text{解出 } y, \\ L^T x = y \implies \text{解出 } x. \end{cases}$$

$$\text{由 } Lz = b \text{ 得 } \begin{cases} z_1 = b_1, \\ z_i = b_i - \sum_{j=1}^{i-1} l_{ij} z_j, \quad i = 2, \dots, n. \end{cases}$$

$$\text{由 } Dy = z \text{ 得 } y_i = z_i / d_i, \quad i = 1, \dots, n$$

$$\text{由 } L^T x = y \text{ 得 } \begin{cases} x_n = y_n, \\ x_i = y_i - \sum_{j=i+1}^n l_{ji} x_j, \quad i = n-1, \dots, 1. \end{cases}$$

改进平方根法的乘除法运算量

$$\textcircled{1} \quad A = LDL^T : \quad N_1 = \frac{1}{6}n^3 + \frac{1}{2}n^2 - \frac{2}{3}n$$

$$\textcircled{2} \quad Lz = b : \quad N_2 = \sum_{i=2}^n (i-1) = \frac{1}{2}n(n-1)$$

$$\textcircled{3} \quad Dy = z : \quad N_3 = n$$

$$\textcircled{4} \quad L^T x = y : \quad N_4 = N_2 = \frac{1}{2}n(n-1)$$

$$N = N_1 + N_2 + N_3 + N_4 = \frac{1}{6}n^3 + \frac{3}{2}n^2 - \frac{2}{3}n$$

改进平方根法的乘除法运算量

$$\textcircled{1} \quad A = LDL^T : \quad N_1 = \frac{1}{6}n^3 + \frac{1}{2}n^2 - \frac{2}{3}n$$

$$\textcircled{2} \quad Lz = b : \quad N_2 = \sum_{i=2}^n (i-1) = \frac{1}{2}n(n-1)$$

$$\textcircled{3} \quad Dy = z : \quad N_3 = n$$

$$\textcircled{4} \quad L^T x = y : \quad N_4 = N_2 = \frac{1}{2}n(n-1)$$

$$N = N_1 + N_2 + N_3 + N_4 = \frac{1}{6}n^3 + \frac{3}{2}n^2 - \frac{2}{3}n$$

- 对比平方根法减少了 n 次乘除法和 n 次开方运算.
- 对比高斯消去法和 Doolittle 分解法,

$$N = \frac{1}{3}n^3 + n^2 - \frac{1}{3}n$$

运算量几乎减少了一半.

三对角线性方程组

在很多应用问题中, 经常会遇到求解三对角线性方程组 $Ax = d$, 即

$$\begin{pmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{pmatrix}.$$

通常情况下, A 是严格对角占优矩阵, 因此存在唯一的 Doolittle 分解.

三对角矩阵的 Doolittle 分解

对于三对角矩阵 A , 其 Doolittle 分解为 $A = LU$, 其中

$$L = \begin{pmatrix} 1 & & & & \\ l_2 & 1 & & & \\ & \ddots & \ddots & & \\ & & l_{n-1} & 1 & \\ & & & l_n & 1 \end{pmatrix}, \quad U = \begin{pmatrix} u_1 & c_1 & & & \\ & u_2 & c_2 & & \\ & & \ddots & \ddots & \\ & & & u_{n-1} & c_{n-1} \\ & & & & u_n \end{pmatrix}.$$

由矩阵乘法可得:

$$\begin{cases} A_{11} = b_1 = U_{11} = u_1, \\ A_{ii} = b_i = L_{i,i-1}U_{i-1,i} + U_{ii} = l_i c_{i-1} + u_i, \quad i = 2, \dots, n, \\ A_{i,i-1} = a_i = L_{i,i-1}U_{i-1,i-1} = l_i u_{i-1}, \quad i = 2, \dots, n, \\ A_{i,i+1} = c_i = L_{ii}U_{i,i+1} = c_i, \quad i = 1, \dots, n-1. \end{cases}$$

追赶法

于是得到

$$\begin{cases} u_1 = b_1, \\ u_i = b_i - l_i c_{i-1}, \quad i = 2, \dots, n, \\ l_i = \frac{a_i}{u_{i-1}}, \quad i = 2, \dots, n. \end{cases}$$

追赶法：用 $A = LU$ 分解求解三对角线性方程组 $Ax = d$, 具体为

$$Ax = d \implies L U x = d \implies \begin{cases} Ly = d, \\ Ux = y. \end{cases}$$

追赶法

$$\text{由 } Ly = d \text{ 得} \quad \begin{cases} y_1 = d_1, \\ y_i = d_i - l_i y_{i-1}, \quad i = 2, \dots, n. \end{cases}$$

$$\text{由 } Ux = y \text{ 得} \quad \begin{cases} x_n = \frac{y_n}{u_n}, \\ x_i = \frac{y_i - c_i x_{i+1}}{u_i}, \quad i = n-1, \dots, 1. \end{cases}$$

“追”：计算 l_i, u_i, y_i .

“赶”：计算 x_i .

追赶法运算量：

$$N = \underbrace{2(n-1)}_{LU \text{ 分解}} + \underbrace{n-1}_{\text{求解 } Ly=d} + \underbrace{2n-1}_{\text{求解 } Ux=y} = 5n - 4 \implies N \sim O(n)$$

追赶法

例 4: 用追赶法求解线性方程组 $Ax = d$, 其中

$$A = \begin{pmatrix} 1 & 2 & 0 & 0 \\ 2 & 3 & 1 & 0 \\ 0 & -3 & 4 & 2 \\ 0 & 0 & 4 & 7 \end{pmatrix}, \quad d = \begin{pmatrix} 5 \\ 6 \\ -12 \\ -1 \end{pmatrix}$$

追赶法

例 4: 用追赶法求解线性方程组 $Ax = d$, 其中

$$A = \begin{pmatrix} 1 & 2 & 0 & 0 \\ 2 & 3 & 1 & 0 \\ 0 & -3 & 4 & 2 \\ 0 & 0 & 4 & 7 \end{pmatrix}, \quad d = \begin{pmatrix} 5 \\ 6 \\ -12 \\ -1 \end{pmatrix}$$

解 ① 根据分解公式依次求得

$$u_1 = 1, \quad l_2 = 2, \quad u_2 = -1, \quad l_3 = 3, \quad u_3 = 1, \quad l_4 = 4, \quad u_4 = -1.$$

于是有

$$L = \begin{pmatrix} 1 & & & \\ 2 & 1 & & \\ & 3 & 1 & \\ & & 4 & 1 \end{pmatrix}, \quad U = \begin{pmatrix} 1 & 2 & & \\ & -1 & 1 & \\ & & 1 & 2 \\ & & & -1 \end{pmatrix}.$$

追赶法

② 求解 $Ly = d$

$$\begin{pmatrix} 1 & & & \\ 2 & 1 & & \\ & 3 & 1 & \\ & & 4 & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \\ -12 \\ -1 \end{pmatrix} \Rightarrow y = \begin{pmatrix} 5 \\ -4 \\ 0 \\ -1 \end{pmatrix}.$$

追赶法

② 求解 $Ly = d$

$$\begin{pmatrix} 1 & & & \\ 2 & 1 & & \\ & 3 & 1 & \\ & & 4 & 1 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \end{pmatrix} = \begin{pmatrix} 5 \\ 6 \\ -12 \\ -1 \end{pmatrix} \Rightarrow y = \begin{pmatrix} 5 \\ -4 \\ 0 \\ -1 \end{pmatrix}.$$

③ 求解 $Ux = y$

$$U = \begin{pmatrix} 1 & 2 & & \\ & -1 & 1 & \\ & & 1 & 2 \\ & & & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{pmatrix} = \begin{pmatrix} 5 \\ -4 \\ 0 \\ -1 \end{pmatrix} \Rightarrow x = \begin{pmatrix} 1 \\ 2 \\ -2 \\ 1 \end{pmatrix}.$$

3. 向量、矩阵范数与误差分析

“误差”

- 若 $x \in \mathbf{R}$, x^* 为近似值, 则 x^* 的准确程度 (或近似 x 的程度)

$$\Delta x = |x - x^*| \implies \text{数的误差}$$

- 若 $x \in \mathbf{R}^n$ ($\mathbf{R}^{n \times n}$), x^* 为近似值, 则 x^* 的准确程度 (或近似 x 的程度)?

向量 (矩阵) 的误差?

向量范数

定义

向量范数 $f(x) : \mathbf{R}^n \longrightarrow \mathbf{R}^+ \cup \{0\}$, $x \longmapsto \|x\|$, 且 $\|x\|$ 满足

(1) 正定性 $\|x\| \geq 0$, $\|x\| = 0 \iff x = 0$;

(2) 齐次性 $\forall \alpha \in \mathbf{R}$, $\|\alpha x\| = |\alpha| \|x\|$;

(3) 三角不等式 $\|x + y\| \leq \|x\| + \|y\|$.

由三角不等式有

$$\|x\| = \|x - y + y\| \leq \|x - y\| + \|y\| \implies \|x\| - \|y\| \leq \|x - y\|,$$

$$\|y\| = \|y - x + x\| \leq \|y - x\| + \|x\| \implies \|x\| - \|y\| \geq -\|x - y\|,$$

于是得到

$$-\|x - y\| \leq \|x\| - \|y\| \leq \|x - y\| \implies \left| \|x\| - \|y\| \right| \leq \|x - y\|.$$

三种常用的向量范数

设 $x \in \mathbf{R}^n$, 则

绝对误差:

- 1-范数: $\|x\|_1 = \sum_{i=1}^n |x_i|$ $\|\Delta x\| = \|x - \tilde{x}\|$

- 2-范数: $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$ 相对误差:

- ∞ -范数: $\|x\|_\infty = \max_{1 \leq i \leq n} |x_i|$ $\frac{\|\Delta x\|}{\|x\|} = \frac{\|x - \tilde{x}\|}{\|x\|}$

例 1: 已知 $x = (1, -3, 6)^T$, 求 $\|x\|_p$ ($p = 1, 2, \infty$).

解 根据向量范数定义有

$$\|x\|_1 = |x_1| + |x_2| + |x_3| = 10,$$

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + x_3^2} = \sqrt{46},$$

$$\|x\|_\infty = \max\{|x_1|, |x_2|, |x_3|\} = 6.$$

向量范数的连续性

定理

设 $\|x\|$ 是 \mathbf{R}^n 上的任一种向量范数, 则 $\|x\|$ 是 x 的连续函数.

证明 只需证当 $x \rightarrow y$ 时, $\|x\| \rightarrow \|y\|$ 即可. 设

$$x = \sum_{i=1}^n x_i e_i, \quad y = \sum_{i=1}^n y_i e_i,$$

其中

$$e_i = (\underbrace{0, 0, \dots, 0}_{i-1 \text{ 个}}, 1, 0, \dots, 0)^T \in \mathbf{R}^n$$

向量范数的连续性

则有

$$\begin{aligned} \left| \|x\| - \|y\| \right| &\leq \|x - y\| = \left\| \sum_{i=1}^n (x_i - y_i) e_i \right\| \leq \sum_{i=1}^n |x_i - y_i| \|e_i\| \\ &\leq \max_{1 \leq i \leq n} |x_i - y_i| \sum_{i=1}^n \|e_i\| = \|x - y\|_{\infty} \sum_{i=1}^n \|e_i\|. \end{aligned}$$

记 $c \triangleq \sum_{i=1}^n \|e_i\|$, 当 $x \rightarrow y$ 时, 有 $\|x - y\| \rightarrow 0$, 因此可得

$$\left| \|x\| - \|y\| \right| \leq c \|x - y\|_{\infty} \rightarrow 0, \quad x \rightarrow y.$$

向量范数的等价性

定理

设 $\|x\|_p$ 和 $\|x\|_q$ 是 \mathbf{R}^n 上的任意两种向量范数, 则存在常数 $c_1 > 0$, $c_2 > 0$, 使得对任意的 $x \in \mathbf{R}^n$ 有

$$c_1 \|x\|_q \leq \|x\|_p \leq c_2 \|x\|_q.$$

证明 设 $S = \{y \in \mathbf{R}^n \mid \|y\|_2 = 1\}$, 则 S 为有界闭集. 根据向量范数的连续性可知 $\|y\|$ 在 S 上连续且存在最大值 $M > 0$ 以及最小值 $m > 0$.

记 $\|y\|_p$ 在 S 上的最大值和最小值分别为 M_p 和 m_p , $\|y\|_q$ 在 S 上的最大值和最小值分别为 M_q 和 m_q .

向量范数的等价性

于是对任意的 $x \in \mathbf{R}^n$, 令 $y = \frac{x}{\|x\|_2}$, 则有 $y \in S$. 因此

$$\frac{m_p}{M_q} \leq \frac{\|x\|_p}{\|x\|_q} = \frac{\|y\|_p}{\|y\|_q} \leq \frac{M_p}{m_q},$$

从而有

$$\frac{m_p}{M_q} \|x\|_q \leq \|x\|_p \leq \frac{M_p}{m_q} \|x\|_q.$$

取

$$c_1 = \frac{m_p}{M_q} > 0, \quad c_2 = \frac{M_p}{m_q} > 0,$$

则定理得证.

向量范数

常用的几个等价关系式：

$$\begin{aligned}\|x\|_{\infty} &\leq \|x\|_1 \leq n\|x\|_{\infty}, \\ \frac{1}{\sqrt{n}}\|x\|_1 &\leq \|x\|_2 \leq \|x\|_1, \\ \frac{1}{\sqrt{n}}\|x\|_2 &\leq \|x\|_{\infty} \leq \|x\|_2.\end{aligned}$$

矩阵范数

定义

矩阵范数 $f(A) : \mathbf{R}^{n \times n} \longrightarrow \mathbf{R}^+ \cup \{0\}$, $A \longmapsto \|A\|$, 且 $\|A\|$ 满足

(1) 正定性 $\|A\| \geq 0$, $\|A\| = 0 \iff A = O$;

(2) 齐次性 $\forall \alpha \in \mathbf{R}$, $\|\alpha A\| = |\alpha| \|A\|$;

(3) 三角不等式 $\|A + B\| \leq \|A\| + \|B\|$;

(4) $\|AB\| \leq \|A\| \|B\|$.

类似地, 由三角不等式有

$$\|A\| = \|A - B + B\| \leq \|A - B\| + \|B\|,$$

$$\|B\| = \|B - A + A\| \leq \|B - A\| + \|A\|,$$

即有

$$|\|A\| - \|B\|| \leq \|A - B\|.$$

矩阵范数的相容性

定义

若矩阵范数 $\|A\|$ 与向量范数 $\|x\|$ 满足

$$\|Ax\| \leq \|A\| \|x\|, \quad \forall x \in \mathbf{R}^n, A \in \mathbf{R}^{n \times n}$$

则称矩阵范数 $\|A\|$ 与向量范数 $\|x\|$ 是相容的.

注意：上式并不是对任意的矩阵范数和向量范数都满足.

矩阵的算子范数

定理

设 $x \in \mathbf{R}^n$, $A \in \mathbf{R}^{n \times n}$, $\|x\|_p$ ($p = 1, 2, \infty$) 是给定的一种向量范数, 相应地定义一个矩阵的非负函数

$$\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = \max_{\|x\|_p=1} \|Ax\|_p,$$

则 $\|A\|_p$ 是一种矩阵范数, 称为矩阵 A 的算子范数, 并且满足相容性条件

$$\|Ax\|_p \leq \|A\|_p \|x\|_p.$$

证明 ① 正定性: 由定义知

$$\|A\|_p = \max_{\|x\|_p=1} \|Ax\|_p \geq 0$$

矩阵的算子范数

且有

$$\|A\|_p = \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = 0$$

$$\iff \forall x \neq 0, \|Ax\|_p = 0$$

$$\iff \forall x \neq 0, Ax = 0 \iff A = O.$$

② 齐次性：对任意的 $\alpha \in \mathbf{R}$,

$$\begin{aligned}\|\alpha A\|_p &= \max_{x \neq 0} \frac{\|\alpha Ax\|_p}{\|x\|_p} = \max_{x \neq 0} \frac{|\alpha| \|Ax\|_p}{\|x\|_p} \\ &= |\alpha| \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} = |\alpha| \|A\|_p.\end{aligned}$$

矩阵的算子范数

③ 三角不等式:

$$\begin{aligned}\|A + B\|_p &= \max_{\|x\|=1} \|(A + B)x\|_p \\ &\leq \max_{\|x\|=1} \|Ax\|_p + \max_{\|x\|=1} \|Bx\|_p = \|A\|_p + \|B\|_p.\end{aligned}$$

④ 相容性: $x = 0$ 的情形显然成立. 而对任意的 $x \neq 0$, 有

$$\begin{aligned}\|A\|_p &= \max_{x \neq 0} \frac{\|Ax\|_p}{\|x\|_p} \geq \frac{\|Ax\|_p}{\|x\|_p}, \\ \implies \|Ax\|_p &\leq \|A\|_p \|x\|_p.\end{aligned}$$

矩阵的算子范数

⑤ 根据相容性有

$$\|ABx\|_p \leq \|A\|_p \|Bx\|_p \leq \|A\|_p \|B\|_p \|x\|_p,$$

于是对任意的 $x \neq 0$, 可以得到

$$\frac{\|ABx\|_p}{\|x\|_p} \leq \|A\|_p \|B\|_p,$$

$$\implies \|AB\|_p = \max_{x \neq 0} \frac{\|ABx\|_p}{\|x\|_p} \leq \|A\|_p \|B\|_p.$$

矩阵的算子范数

定理

设 $x \in \mathbf{R}^n$, $A \in \mathbf{R}^{n \times n}$, 则对应于向量的三种范数 $\|x\|_p$ ($p = 1, 2, \infty$) 的矩阵范数分别为

$$(1) \|A\|_1 = \max_{1 \leq j \leq n} \left(\sum_{i=1}^n |a_{ij}| \right) \quad 1 - \text{范数或列范数};$$

$$(2) \|A\|_2 = \sqrt{\lambda_{\max}(A^T A)} \quad 2 - \text{范数或谱范数};$$

$$(3) \|A\|_{\infty} = \max_{1 \leq i \leq n} \left(\sum_{j=1}^n |a_{ij}| \right) \quad \infty - \text{范数或行范数},$$

其中 $\lambda_{\max}(A^T A)$ 表示矩阵 $A^T A$ 的最大特征值.

矩阵的算子范数

证明 设 $x = (x_1, x_2, \dots, x_n)^T$,

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{pmatrix} = (a_1, a_2, \dots, a_n),$$

其中

$$a_j = (a_{1j}, a_{2j}, \dots, a_{nj})^T \quad (j = 1, 2, \dots, n).$$

矩阵的算子范数

(1) 对于 1-范数, 由算子范数定义有 $\|A\|_1 = \max_{\|x\|=1} \|Ax\|_1$, 且

$$\begin{aligned}\|Ax\|_1 &= \left\| \sum_{j=1}^n x_j a_j \right\|_1 \leq \sum_{j=1}^n |x_j| \|a_j\|_1 \\ &\leq \sum_{j=1}^n |x_j| \cdot \max_{1 \leq j \leq n} \|a_j\|_1 = \|x\|_1 \cdot \max_{1 \leq j \leq n} \|a_j\|_1,\end{aligned}$$

则
$$\|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 \leq \max_{1 \leq j \leq n} \|a_j\|_1 = \max_{1 \leq j \leq n} \left(\sum_{i=1}^n |a_{ij}| \right).$$

取 $x = e_k$, 其中 k 满足 $\max_{1 \leq j \leq n} \|a_j\|_1 = \|a_k\|_1$, 则有

$$\|Ax\|_1 = \|Ae_k\|_1 = \|a_k\|_1 = \max_{1 \leq j \leq n} \|a_j\|_1,$$

即有
$$\|A\|_1 = \max_{\|x\|_1=1} \|Ax\|_1 = \max_{1 \leq j \leq n} \|a_j\|_1 = \max_{1 \leq j \leq n} \left(\sum_{i=1}^n |a_{ij}| \right).$$

矩阵的算子范数

(2) 对于 2-范数, 我们注意到

$$\|Ax\|_2^2 = (Ax)^T Ax = x^T A^T Ax \geq 0, \quad \forall x \in \mathbf{R}^n,$$

因此 $A^T A$ 是对称正定或对称半正定矩阵. 奇异值分解, 谱分解

由线性代数知识知, $A^T A$ 有 n 个非负特征值 λ_i ($i = 1, \dots, n$), 记为

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0,$$

其对应的标准正交特征向量为 u_1, u_2, \dots, u_n .

对任意的 $x \in \mathbf{R}^n$, 由于 $\{u_i\}_{i=1}^n$ 是 \mathbf{R}^n 的一组基向量, 因此存在 k_1, k_2, \dots, k_n 使得

$$x = \sum_{i=1}^n k_i u_i \quad \text{且} \quad \|x\|_2^2 = x^T x = \sum_{i=1}^n k_i^2.$$

矩阵的算子范数

于是

$$\begin{aligned}\|A\|_2 &= \max_{\|x\|_2=1} \|Ax\|_2 = \max_{\|x\|_2=1} \sqrt{x^T A^T A x} \\&= \max_{\|x\|_2=1} \sqrt{\sum_{i=1}^n k_i u_i^T \cdot \sum_{j=1}^n A^T A k_j u_j} \\&= \max_{\|x\|_2=1} \sqrt{\sum_{i=1}^n k_i u_i^T \cdot \sum_{j=1}^n \lambda_j k_j u_j} \\&= \max_{\|x\|_2=1} \sqrt{\sum_{i=1}^n \lambda_i k_i^2} \leq \max_{\|x\|_2=1} \sqrt{\lambda_1 \sum_{i=1}^n k_i^2} = \sqrt{\lambda_1}.\end{aligned}$$

矩阵的算子范数

特别地, 取 $x = u_1$, 则有 $\|x\|_2 = 1$ 以及

$$\|Ax\|_2^2 = u_1^T A^T A u_1 = u_1^T \lambda_1 u_1 = \lambda_1,$$

因此有

$$\|A\|_2 = \max_{\|x\|_2=1} \|Ax\|_2 = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(A^T A)}.$$

(3) 对于 ∞ -范数, 对任意的 $x \in \mathbf{R}^n$, 设 k 满足

$$\max_{1 \leq i \leq n} \left(\sum_{j=1}^n |a_{ij}| \right) = \sum_{j=1}^n |a_{kj}|,$$

则有

$$\begin{aligned} \|Ax\|_\infty &= \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} x_j \right| \leq \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| |x_j| \\ &\leq \max_{1 \leq j \leq n} |x_j| \cdot \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| = \|x\|_\infty \sum_{j=1}^n |a_{kj}|. \end{aligned}$$

矩阵的算子范数

取 $x = (\operatorname{sgn}(a_{k1}), \operatorname{sgn}(a_{k2}), \dots, \operatorname{sgn}(a_{kn}))^T$, 则有 $\|x\|_\infty = 1$. 于是有

$$\|Ax\|_\infty = \max_{1 \leq i \leq n} \left| \sum_{j=1}^n a_{ij} \cdot \operatorname{sgn}(a_{kj}) \right| = \sum_{j=1}^n |a_{kj}|,$$

因此有

$$\|A\|_\infty = \max_{\|x\|_\infty=1} \|Ax\|_\infty = \sum_{j=1}^n |a_{kj}| = \max_{1 \leq i \leq n} \left(\sum_{j=1}^n |a_{ij}| \right).$$

矩阵的算子范数

例 2: 求矩阵 $A = \begin{pmatrix} 1 & 3 \\ 4 & 2 \end{pmatrix}$ 的 3 种算子范数.

解

$$\|A\|_1 = \max\{5, 5\} = 5, \quad \|A\|_\infty = \max\{4, 6\} = 6.$$

$$A^T A = \begin{pmatrix} 1 & 4 \\ 3 & 2 \end{pmatrix} \begin{pmatrix} 1 & 3 \\ 4 & 2 \end{pmatrix} = \begin{pmatrix} 17 & 11 \\ 11 & 13 \end{pmatrix},$$

$$|\lambda I - A^T A| = \begin{vmatrix} \lambda - 17 & -11 \\ -11 & \lambda - 13 \end{vmatrix} = \lambda^2 - 30\lambda + 100 = 0,$$

$$\implies \lambda_1 = 15 + 5\sqrt{5}, \quad \lambda_2 = 15 - 5\sqrt{5}.$$

于是有

$$\|A\|_2 = \lambda_{\max}(A^T A) = 15 + 5\sqrt{5}.$$

矩阵范数

F-范数

$$\|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}$$

F-范数与向量2-范数的相容性

$$\begin{aligned}\|Ax\|_2^2 &= \sum_{i=1}^n \left(\sum_{j=1}^n a_{ij} x_j \right)^2 = \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n a_{ij} x_j \cdot a_{ik} x_k \\ &\leq \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n (a_{ij}^2 x_k^2 + a_{ik}^2 x_j^2) = \sum_{i=1}^n \sum_{j=1}^n \sum_{k=1}^n a_{ij}^2 x_k^2 \\ &= \left(\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2 \right) \cdot \left(\sum_{k=1}^n x_k^2 \right) = \|A\|_F^2 \cdot \|x\|_2^2\end{aligned}$$

两边开方即得

$$\|Ax\|_2 \leq \|A\|_F \|x\|_2.$$

矩阵范数

定理

设 $\|A\|_p$ 和 $\|A\|_q$ 是 $\mathbf{R}^{n \times n}$ 中任意两种矩阵范数, 则存在常数 $c_1 > 0$, $c_2 > 0$ 使得

$$c_1 \|A\|_q \leq \|A\|_p \leq c_2 \|A\|_q, \quad \forall A \in \mathbf{R}^{n \times n}.$$

定义

设 $A \in \mathbf{R}^{n \times n}$, λ_i ($i = 1, 2, \dots, n$) 是 A 的特征值, 则

$$\rho(A) = \max_{1 \leq i \leq n} \{|\lambda_i|\}$$

称为矩阵 A 的谱半径.

定理

设 $A \in \mathbf{R}^{n \times n}$, 则有 $\rho(A) \leq \|A\|$, 即谱半径不超过 A 的任意一种范数.

矩阵范数

定理

设 $A \in \mathbf{R}^{n \times n}$, 则有 $\rho(A) \leq \|A\|$, 即谱半径不超过 A 的任意一种范数. 谱半径是矩阵范数的下确界

证明 设 λ 是 A 的任一特征值, x 是对应的特征向量, 则

$$Ax = \lambda x,$$

于是有

$$|\lambda| \|x\| = \|\lambda x\| = \|Ax\| \leq \|A\| \|x\|.$$

注意到 $x \neq 0$, 即 $\|x\| > 0$. 因此

$$|\lambda| \leq \|A\| \implies \rho(A) = \max_{1 \leq i \leq n} \{|\lambda_i|\} \leq \|A\|.$$

矩阵的算子范数

定理

设 $\|A\| < 1$, 则 $I - A$ 是可逆矩阵, 且

$$\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$

矩阵的算子范数

定理

设 $\|A\| < 1$, 则 $I - A$ 是可逆矩阵, 且

$$\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$

证明 (反证法) 假定 $I - A$ 不可逆, 则线性方程组

$$(I - A)x = 0$$

有非零解, 即存在 $\tilde{x} \neq 0$ 使得 $\tilde{x} = A\tilde{x}$.

两边取与矩阵范数相容的向量范数, 得

$$\|\tilde{x}\| = \|A\tilde{x}\| \leq \|A\|\|\tilde{x}\| \implies (1 - \|A\|)\|\tilde{x}\| \leq 0.$$

矩阵的算子范数

由于 $\|\tilde{x}\| > 0$, 于是有

$$1 - \|A\| \leq 0 \implies \|A\| \geq 1$$

与已知条件 $\|A\| < 1$ 矛盾. 因此 $I - A$ 可逆.

由 $(I - A)^{-1}(I - A) = I$ 可得

$$(I - A)^{-1} = I + A(I - A)^{-1}.$$

两边同取算子范数, 得到

$$\|(I - A)^{-1}\| \leq \|I\| + \|A\| \|(I - A)^{-1}\|,$$

因此有

$$(1 - \|A\|) \|(I - A)^{-1}\| \leq \|I\| = 1.$$

由已知条件 $\|A\| < 1$ 即可得到

$$\|(I - A)^{-1}\| \leq \frac{1}{1 - \|A\|}.$$

舍入误差对解的影响

假设准确解 x 满足线性方程组

$$Ax = b.$$

受原始数据精度以及计算机字长的限制影响, A 和 b 产生微小扰动 (误差) $\Delta A, \Delta b$, 于是近似解 \tilde{x} 满足扰动后的方程组, 即

$$(A - \Delta A)\tilde{x} = b - \Delta b$$

$$\Downarrow$$

$$(A - \Delta A)(x - \Delta x) = b - \Delta b$$

解的相对误差估计

定理

设线性方程组 $Ax = b$ ($|A| \neq 0, b \neq 0$) 的系数矩阵 A 和右端项 b 有微小的扰动 $\Delta A, \Delta b$, 扰动后的方程组为

$$(A + \Delta A)(x + \Delta x) = b + \Delta b.$$

当 $\|A^{-1}\|\|\Delta A\| < 1$ 时, 则 $Ax = b$ 的近似解 \tilde{x} 的相对误差估计式为

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A\|\|A^{-1}\|}{1 - \|A\|\|A^{-1}\|\frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right).$$

解的相对误差估计

证明 由 $(A - \Delta A)(x - \Delta x) = b - \Delta b$ 及 $Ax = b$ 可知

$$A\Delta x = \Delta b - \Delta Ax + \Delta A\Delta x,$$

即

$$\Delta x = A^{-1}\Delta b - A^{-1}\Delta Ax + A^{-1}\Delta A\Delta x,$$

于是得到

$$\|\Delta x\| \leq \|A^{-1}\| \|\Delta b\| + \|A^{-1}\| \|\Delta A\| \|x\| + \|A^{-1}\| \|\Delta A\| \|\Delta x\|,$$

即

$$\|\Delta x\| (1 - \|A^{-1}\| \|\Delta A\|) \leq \|A^{-1}\| \|\Delta b\| + \|A^{-1}\| \|\Delta A\| \|x\|,$$

$$\Rightarrow \|\Delta x\| \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\| \|\Delta A\|} (\|\Delta b\| + \|\Delta A\| \|x\|).$$

解的相对误差估计

两边同除 $\|x\|$ 得到

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|} \left(\frac{\|\Delta b\|}{\|x\|} + \|\Delta A\| \right).$$

注意到

$$\|b\| = \|Ax\| \leq \|A\|\|x\| \implies \frac{1}{\|x\|} \leq \frac{\|A\|}{\|b\|}.$$

于是有

$$\begin{aligned} \frac{\|\Delta x\|}{\|x\|} &\leq \frac{\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|} \left(\frac{\|A\|\|\Delta b\|}{\|b\|} + \|\Delta A\| \right) \\ &= \frac{\|A\|\|A^{-1}\|}{1 - \|A^{-1}\|\|\Delta A\|} \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right) \\ &= \frac{\|A\|\|A^{-1}\|}{1 - \|A\|\|A^{-1}\|\frac{\|\Delta A\|}{\|A\|}} \left(\frac{\|\Delta b\|}{\|b\|} + \frac{\|\Delta A\|}{\|A\|} \right). \end{aligned}$$

解的相对误差估计

可以看出, 当 $\frac{\|\Delta A\|}{\|A\|}$ 较小时, 近似解的相对误差约为 A 的相对误差与 b 的相对误差的乘积的 $\|A\|\|A^{-1}\|$ 倍.

由于

$$1 = \|I\| = \|AA^{-1}\| \leq \|A\|\|A^{-1}\|,$$

因此误差被放大.

当 $\|A\|\|A^{-1}\|$ 较小时, 解的相对误差就小; 反之就大.

$\|A\|\|A^{-1}\|$ 反映了原始数据对解的影响. 如何衡量它的大小?

矩阵的条件数

定义

设 A 是非奇异矩阵, $\text{Cond}(A) \triangleq \|A\| \|A^{-1}\|$ 称为矩阵的条件数.

常用的矩阵条件数

$$(1) \quad \text{Cond}_{\infty}(A) = \|A\|_{\infty} \|A^{-1}\|_{\infty};$$

$$(2) \quad \text{Cond}_2(A) = \|A\|_2 \|A^{-1}\|_2 = \sqrt{\frac{\lambda_{\max}(A^T A)}{\lambda_{\min}(A^T A)}}.$$

当 A 对称时,

$$\text{Cond}_2(A) = \frac{|\lambda_1|}{|\lambda_n|},$$

其中 λ_1 是 A 的绝对值最大的特征值, λ_n 是 A 的绝对值最小的特征值.

矩阵的条件数

关于矩阵的条件数, 有如下性质

- (1) $\text{Cond}(A) \geq 1$.
- (2) $\forall k \neq 0, \text{Cond}(kA) = \text{Cond}(A)$.
- (3) A 是正交矩阵时, $\text{Cond}_2(A) = 1$.
- (4) A 是对称矩阵时, $\text{Cond}_2(A) = \frac{|\lambda_1|}{|\lambda_n|}$.

矩阵的条件数刻画了线性方程组 $Ax = b$ 的性态.

A 条件数大 $\implies A$ 病态矩阵; $Ax = b$ 病态方程组.

A 条件数小 $\implies A$ 良态矩阵; $Ax = b$ 良态方程组.

Ill-posed,
Well-posed

矩阵的条件数

例 3: 已知 $Ax = b$ 有如下形式:

$$\begin{pmatrix} 1 & 1.0001 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}.$$

- (1) 求 $\text{Cond}_\infty(A)$ 和 $Ax = b$ 的解 x .
- (2) 设 $b - \Delta b = (2.0001, 2)^T$, 求 \tilde{x} .
- (3) 在 (2) 的条件下求 $\frac{\|\Delta b\|_\infty}{\|b\|_\infty}$ 和 $\frac{\|\Delta x\|_\infty}{\|x\|_\infty}$.

解 (1) 易知 $x = (2, 0)^T$ 以及

$$A^{-1} = \begin{pmatrix} -10^4 & 1.0001 \times 10^4 \\ 10^4 & -10^4 \end{pmatrix},$$

于是有 $\|A\|_\infty = 2.0001$, $\|A^{-1}\|_\infty = 2.0001 \times 10^4$,

$$\text{Cond}_\infty(A) = \|A\|_\infty \|A^{-1}\|_\infty = 2.0001 \times 2.0001 \times 10^4 \approx 4 \times 10^4.$$

矩阵的条件数

(2)

$$\begin{pmatrix} 1 & 1.0001 \\ 1 & 1 \end{pmatrix} \begin{pmatrix} \tilde{x}_1 \\ \tilde{x}_2 \end{pmatrix} = \begin{pmatrix} 2.0001 \\ 2 \end{pmatrix} \implies \tilde{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

(3) 由 (1) 和 (2) 可知

$$\begin{aligned} \|\Delta b\|_\infty &= 0.0001, & \|b\|_\infty &= 2, \\ \|\Delta x\|_\infty &= 1, & \|x\|_\infty &= 2, \end{aligned}$$

于是有

$$\begin{aligned} \frac{\|\Delta b\|_\infty}{\|b\|_\infty} &= \frac{0.0001}{2} = 0.005\%, \\ \frac{\|\Delta x\|_\infty}{\|x\|_\infty} &= \frac{1}{2} = 50\%. \end{aligned}$$

病态方程组的判别

- (1) $|\det(A)|$ 很小, 或者 A 的某些行或列近似线性相关
- (2) A 的元素数量级相差悬殊
- (3) 用列主元高斯消去法求解时, 出现量级很小的列主元
- (4) 解对原始数据的变化比较敏感
- (5) 求出的解与预期相差较大

病态方程组的求解

- (1) 采用高精度算法, 如双精度, 减少舍入误差
- (2) 采用数值稳定性好的算法
- (3) 平衡法: 当 A 的元素数量级相差很大时, 采用行平衡或列平衡方法, 降低条件数

行平衡: $s_i = \max_{1 \leq j \leq n} |a_{ij}|, \quad i = 1, 2, \dots, n$

令 $D = \text{diag} \left(\frac{1}{s_1}, \frac{1}{s_2}, \dots, \frac{1}{s_n} \right)$, 然后求解方程

$$DAx = Db.$$

病态方程组的求解

例 4: 原 $Ax = b$:

$$\begin{pmatrix} 0.1 & 0.1 \\ 0.1 & 10^{10} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0.2 \\ 10^{10} \end{pmatrix},$$

$$\text{Cond}_\infty(A) \approx 10^{11} \implies \text{病态方程组}$$

采用行平衡方法, 有

$$D = \text{diag}(10, 10^{-10}),$$

于是得到新的方程组

$$\begin{pmatrix} 1 & 1 \\ 10^{-11} & 1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix},$$

$$\text{Cond}_\infty(DA) = 4 \implies \text{良态方程组}$$

病态方程组的求解

(4) 迭代改善技术 (残差修正法)

设 \tilde{x} 为 $Ax = b$ 的一个近似解, 求修正量 $\Delta\tilde{x}$ 使得

$$A(\tilde{x} + \Delta\tilde{x}) = b \implies A\Delta\tilde{x} = b - A\tilde{x}.$$

定义残向量

$$r \triangleq b - A\tilde{x},$$

于是有

$$A\Delta\tilde{x} = r,$$

求解得到 $\Delta\tilde{x}$, 则 $\tilde{x} + \Delta\tilde{x}$ 为 $Ax = b$ 更为准确的近似解.

令 $\tilde{\tilde{x}} = \tilde{x} + \Delta\tilde{x}$, 用上述过程再进行修正, 直到满足精度要求.